

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN - TIN

ĐỒ ÁN CHUỖI THỜI GIAN

Nghiên cứu cải tiến mô hình TimeXer
dựa trên mức độ tương quan thời gian và
ứng dụng trong dự báo lượng tiêu thụ
điện năng

Lê Việt Bách - 20237302
Nguyễn Văn Đông - 20237309
Đào Việt Trung - 20237396

Chuyên ngành: Toán - Tin

Giảng viên hướng dẫn: PGS.TS. Nguyễn Thị Ngọc Anh

HÀ NỘI – 2026

Mục lục

Bảng ký hiệu	1
Mở đầu	3
Chương 1 Tổng quan đề tài	4
1.1 Lý do chọn đề tài	4
1.2 Mục tiêu nghiên cứu	4
1.3 Phạm vi và đối tượng nghiên cứu	5
Chương 2 Cơ sở lý thuyết	7
2.1 Bài toán dự báo chuỗi thời gian	7
2.2 Các đặc trưng thời gian và mùa vụ	8
2.3 Các mô hình cơ sở	9
2.4 Các mô hình có yếu tố mùa vụ	10
2.5 Các mô hình học sâu cho chuỗi thời gian	11
2.6 Mô hình TimeXer	13
2.6.1 Nhúng biến nội sinh theo đoạn (patch embedding)	13
2.6.2 Nhúng biến ngoại sinh theo biến số (variate embedding)	14
2.6.3 Cơ chế chú ý và luồng thông tin	14
2.6.4 Những hạn chế làm cơ sở cho cải tiến	14
2.7 Cơ sở lý thuyết về mức độ tương quan thời gian (Time Correlation)	15
2.7.1 Hàm tự tương quan và tự tương quan riêng phần	15
2.7.2 Hệ số tương quan Pearson	15
2.7.3 Tương quan khoảng cách (distance correlation)	16
2.7.4 Hàm tương quan chéo và độ trễ	16
Chương 3 Tiền xử lý dữ liệu	17

3.1	Khảo sát và mô tả dữ liệu	17
3.2	Kiểm tra chất lượng dữ liệu	18
3.3	Trích xuất đặc trưng (Feature Engineering)	19
3.4	Phân tích tương quan thời gian	19
3.5	Chuẩn hóa dữ liệu	21
3.6	Chia tập dữ liệu	21
Chương 4	Đề xuất cải tiến: Hàm loss dựa trên mức độ tương quan thời gian	22
4.1	Phân tích hạn chế của loss function truyền thống trong TimeXer	22
4.2	Ý tưởng đề xuất: Time-Correlation Weighted Loss	22
4.3	Phương án tích hợp vào kiến trúc TimeXer	24
4.4	Các phương án loss thay thế để so sánh (ablation)	24
Chương 5	Xây dựng mô hình	25
5.1	Nhóm mô hình Baseline	25
5.2	Nhóm mô hình có yếu tố mùa vụ	25
5.3	Nhóm mô hình Deep Learning	26
5.4	Mô hình TimeXer (gốc)	26
5.5	Mô hình TimeXer cải tiến (đề xuất của nhóm)	26
5.5.1	Pha 1: Lập hồ sơ liên quan phi tuyến theo độ trễ	27
5.5.2	Pha 2: Căn độ trễ và cổng liên quan học được	28
5.5.3	Mô hình kết hợp	29
Chương 6	Thực nghiệm và đánh giá	30
6.1	Thiết lập thực nghiệm	30
6.2	Các chỉ số đánh giá	30
6.3	Bảng so sánh kết quả tổng hợp	30
6.4	Trực quan hóa kết quả	31
6.5	Phân tích ablation	32
6.6	Phân tích định tính	33
Chương 7	Kết luận và hướng phát triển	35
7.1	Kết quả đạt được	35

7.2	Hạn chế của đề tài	35
7.3	Hướng phát triển	36

BẢNG KÝ HIỆU

Ký hiệu toán học

L	Độ dài cửa sổ nhìn lại (lookback), $L = 168$ giờ.
H	Tầm dự báo (horizon), $H = 24$ giờ.
P	Độ dài đoạn (patch length), $P = 24$.
d	Số chiều không gian ẩn của mô hình.
$X_{[t-L+1:t]}$	Mã trận quan sát đầu vào trong cửa sổ nhìn lại.
$y_{t+h}, \hat{y}_{t+h}$	Giá trị thực và giá trị dự báo tại bước $t + h$.
$\rho(k)$	Hàm tự tương quan tại độ trễ k (ACF).
$\rho_{xy}(\tau)$	Hàm tương quan chéo giữa x và y tại độ trễ τ (CCF).
dCor	Tương quan khoảng cách (distance correlation).
$R_j(\tau)$	Hồ sơ liên quan phi tuyến của biến ngoại sinh j theo độ trễ.
τ_j^*, R_j^*	Độ trễ trội và điểm liên quan của biến ngoại sinh j .
g_j	Cổng liên quan học được cho biến ngoại sinh j .
ψ_k	Trọng số biểu diễn trung bình trượt vô hạn MA(∞).
Σ_ψ	Mã trận hiệp phương sai sai số dự báo.
w_h^{invvar}	Trọng số nghịch phương sai cho horizon h .
W	Mã trận chính xác (precision) đã co rút trong CorrStruct Loss.
σ_{load}	Độ lệch chuẩn của phụ tải trên tập huấn luyện.

Từ viết tắt

ACF, PACF	Hàm tự tương quan, hàm tự tương quan riêng phần.
CCF	Hàm tương quan chéo.
dCor	Tương quan khoảng cách.
MAE, MSE, RMSE	Các chỉ số sai số dự báo.
ADF	Kiểm định nghiệm đơn vị Augmented Dickey–Fuller.
AR, MA	Tự hồi quy, trung bình trượt.
SARIMAX	Mô hình ARIMA mùa vụ có biến ngoại sinh.

LSTM, GRU	Các mạng nơ-ron hồi quy có cổng.
MW	Megawatt (đơn vị phụ tải).

MỞ ĐẦU

Dự báo phụ tải điện năng là một bài toán có ý nghĩa thực tiễn lớn, phục vụ trực tiếp công tác vận hành lưới điện, lập kế hoạch sản xuất và tối ưu chi phí. Trong những năm gần đây, các kiến trúc Transformer cho chuỗi thời gian, tiêu biểu là TimeXer, đã đạt hiệu quả cao nhờ khả năng phối hợp biểu diễn biến nội sinh và biến ngoại sinh. Tuy vậy, TimeXer gốc vẫn còn những hạn chế: hàm mất mát đối xử đồng đều với mọi bước dự báo bất chấp cấu trúc tương quan thời gian, và cơ chế chú ý chéo chưa mô hình hóa tường minh độ trễ cũng như mức liên quan phi tuyến của biến ngoại sinh.

Xuất phát từ đó, đề tài đề xuất hai cải tiến trực giao cho TimeXer. Thứ nhất, một hàm mất mát có trọng số theo mức độ tương quan thời gian (Time-Correlation Weighted Loss), trong đó trọng số được suy ra một cách có nguyên tắc từ cấu trúc hiệp phương sai sai số dự báo của chuỗi. Thứ hai, một cơ chế biến ngoại sinh nhận biết độ trễ và chọn lọc theo tương quan khoảng cách (XCorr-Lag Exogenous), cho phép mô hình tự động xác định biến ngoại sinh nào quan trọng và ở độ trễ nào, kể cả khi quan hệ là phi tuyến. Cả hai cải tiến đều được thiết kế sao cho thu về đúng TimeXer gốc dưới tham số tầm thường, bảo đảm tính so sánh công bằng.

Báo cáo được tổ chức thành bảy chương. Chương 1 trình bày tổng quan đề tài. Chương 2 hệ thống hóa cơ sở lý thuyết về dự báo chuỗi thời gian, các mô hình nền và lý thuyết tương quan. Chương 3 mô tả quy trình tiền xử lý dữ liệu. Chương 4 trình bày cải tiến về hàm loss. Chương 5 mô tả việc xây dựng mô hình và cơ chế biến ngoại sinh đề xuất. Chương 6 trình bày thực nghiệm, kết quả và phân tích ablation. Chương 7 tổng kết kết quả, hạn chế và hướng phát triển.

CHƯƠNG 1

TỔNG QUAN ĐỀ TÀI

1.1 Lý do chọn đề tài

Điện năng là nguồn năng lượng huyết mạch, đóng vai trò cốt lõi trong mọi hoạt động sản xuất và đời sống kinh tế - xã hội. Do đó, việc dự báo chính xác lượng tiêu thụ điện năng mang một tầm quan trọng đặc biệt, hỗ trợ trực tiếp cho công tác vận hành lưới điện, lập kế hoạch sản xuất và tối ưu hóa chi phí một cách hiệu quả. Một hệ thống dự báo tốt sẽ giúp các nhà quản lý ngăn ngừa tình trạng thiếu hụt năng lượng gây đình trệ sản xuất, đồng thời tránh việc dư thừa công suất dẫn đến lãng phí tài nguyên.

Để giải quyết bài toán dự báo chuỗi thời gian như tiêu thụ điện năng, nhiều mô hình học sâu đã được áp dụng và mang lại hiệu quả cao. Tuy nhiên, các kiến trúc Transformer truyền thống hiện nay vẫn bộc lộ những hạn chế nhất định. Cụ thể, cơ chế attention trong các mô hình này thường đánh giá và xử lý các điểm dữ liệu một cách độc lập, chưa thực sự phân biệt rõ ràng mức độ tương quan thời gian giữa các bước thời gian khác nhau. Điều này làm giảm khả năng nắm bắt tính chu kỳ và sự phụ thuộc theo thời gian vốn rất đặc trưng trong dữ liệu điện năng.

Xuất phát từ những hạn chế trên, nhóm nghiên cứu đã tìm thấy động lực để tiến hành cải tiến mô hình TimeXer. Trọng tâm của sự cải tiến này là thay thế các hàm mất mát (loss function) truyền thống bằng một hàm loss mới được tích hợp trọng số dựa trên mức độ tương quan thời gian. Giải pháp này được kỳ vọng sẽ giúp mô hình tập trung học được những đặc trưng quan trọng nhất giữa các khoảng thời gian có độ tương quan cao, từ đó nâng cao đáng kể độ chính xác và tính ổn định trong việc dự báo lượng tiêu thụ điện năng.

1.2 Mục tiêu nghiên cứu

Để giải quyết những hạn chế của các mô hình hiện tại và đáp ứng nhu cầu thực tiễn trong bài toán dự báo, đề tài đặt ra ba mục tiêu nghiên cứu cụ thể như sau:

- Thứ nhất, xây dựng một pipeline dự báo tiêu thụ điện năng hoàn chỉnh. Đề tài hướng tới việc thiết lập một quy trình chuẩn hóa từ đầu đến cuối, bao gồm các khâu: thu thập và làm sạch dữ liệu, trích xuất đặc trưng (feature engineering) liên quan đến thời gian và mùa vụ, cho đến huấn luyện, triển khai và đánh giá mô hình.
- Thứ hai, đề xuất một hàm mất mát (loss function) mới dựa trên mức độ tương quan thời gian, gọi là Time-Correlation Weighted Loss. Thay vì sử dụng các hàm loss truyền thống đánh giá sai số đồng đều ở mọi bước thời gian, nghiên cứu sẽ thiết kế một hàm loss tích hợp trọng số tương quan nhằm giúp mô hình TimeXer tập trung vào các khoảng thời gian có ảnh hưởng lớn nhất đến kết quả dự báo.
- Thứ ba, tiến hành thực nghiệm và so sánh hiệu quả của mô hình cải tiến với các mô hình cơ sở và các mô hình tiên tiến hiện nay. Bằng cách đánh giá trên các chỉ số đo lường sai số chuẩn, nghiên cứu sẽ phân tích và chứng minh tính ưu việt của phương pháp đề xuất so với các mô hình học máy truyền thống, mô hình học sâu (Deep Learning) và cả phiên bản TimeXer gốc.

1.3 Phạm vi và đối tượng nghiên cứu

Đối tượng nghiên cứu: Đối tượng trọng tâm của đề án là bài toán dự báo chuỗi thời gian (time series forecasting) và các kiến trúc học sâu hiện đại, đặc biệt là mô hình TimeXer. Bên cạnh đó, nghiên cứu cũng đi sâu vào các phương pháp đánh giá mức độ tương quan thời gian (như ACF, PACF, hệ số Pearson) và cơ chế tối ưu hóa quá trình học của mô hình thông qua việc tùy chỉnh hàm mất mát (loss function).

Phạm vi nghiên cứu:

- **Về mặt dữ liệu:** Quá trình huấn luyện, kiểm thử và đánh giá mô hình được thực hiện trên tập dữ liệu chuỗi thời gian về lượng tiêu thụ điện năng. (Lưu ý cho bạn: Tại đây, bạn cần ghi rõ quy mô thu thập dữ liệu là của hộ gia đình, khu vực hay cấp quốc gia, đồng thời trích dẫn rõ tên nguồn dataset đang sử dụng, ví dụ như bộ dữ liệu UCI Electricity, ETT, hay dữ liệu từ EVN, v.v.).
- **Về mặt bài toán:** Đề tài giới hạn phạm vi trong việc giải quyết bài toán dự báo lượng tiêu thụ điện năng, bao gồm cả dự báo đơn bước (single-step forecasting) và dự báo đa bước (multi-step forecasting). Trọng tâm là đánh giá hiệu suất, độ chính

xác và khả năng nắm bắt xu hướng của mô hình khi dự báo các giá trị trong tương lai dựa trên chuỗi dữ liệu đầu vào trong quá khứ.

CHƯƠNG 2

CƠ SỞ LÝ THUYẾT

2.1 Bài toán dự báo chuỗi thời gian

Dự báo chuỗi thời gian là quá trình phân tích và sử dụng các tập dữ liệu được ghi nhận tuần tự theo thời gian trong quá khứ nhằm trích xuất các quy luật, xu hướng và tính chu kỳ, từ đó ước lượng hoặc dự đoán các giá trị sẽ xảy ra trong tương lai. Trong phạm vi nghiên cứu của đề tài, bài toán tập trung vào việc mô hình hóa sự phụ thuộc thời gian để dự báo lượng tiêu thụ điện năng.

Bài toán dự báo có thể được hình thức hóa thành quá trình tìm kiếm một hàm ánh xạ từ tập dữ liệu lịch sử đầu vào sang giá trị dự báo đầu ra. Cụ thể, định nghĩa input và output được mô tả như sau:

- Dữ liệu đầu vào (Input):** Được biểu diễn qua ma trận

$$X_{[t-L+1:t]} \in \mathbb{R}^{L \times d}.$$

Trong đó, ma trận này đại diện cho chuỗi các quan sát liên tiếp trong lịch sử tính đến bước thời gian hiện tại t .

- Giá trị đầu ra (Output):** Là mục tiêu dự báo được ký hiệu là

$$y_{t+h} \in \mathbb{R}.$$

Đây là giá trị đơn biến (ở đây là lượng tiêu thụ điện năng) tại một thời điểm trong tương lai.

Để chuyển đổi chuỗi thời gian thành dạng dữ liệu có nhãn phục vụ cho quá trình huấn luyện có giám sát (*supervised learning*), nghiên cứu áp dụng các khái niệm và kỹ thuật cơ sở sau:

- Lookback length (L):** Là tham số xác định độ dài của chuỗi dữ liệu lịch sử được đưa vào làm đầu vào tại mỗi bước dự báo. Kích thước của chuỗi quan sát này quyết định lượng bối cảnh thông tin quá khứ mà mô hình có thể thu nhận để học các quy luật.

- **Horizon (h):** Hay còn gọi là tầm nhìn dự báo, đại diện cho khoảng cách (số bước thời gian) từ thời điểm hiện tại đến thời điểm mục tiêu $t + h$ cần được dự báo.
- **Sliding window (Cửa sổ trượt):** Đây là kỹ thuật lấy mẫu cốt lõi trong xử lý dữ liệu chuỗi thời gian. Kỹ thuật này sử dụng một cửa sổ có kích thước cố định bằng độ dài L , trượt tuần tự dọc theo trục thời gian của tập dữ liệu để cắt ra các chuỗi con làm đặc trưng đầu vào (input) và kết hợp với giá trị tại bước thời gian cách đó khoảng h làm nhãn (output) tương ứng.

2.2 Các đặc trưng thời gian và mùa vụ

Trong phân tích và dự báo chuỗi thời gian, đặc biệt đối với bài toán tiêu thụ điện năng, dữ liệu luôn chứa đựng các quy luật lặp lại và chịu sự chi phối mạnh mẽ của yếu tố chu kỳ. Do đó, việc thực hiện trích xuất đặc trưng một cách hiệu quả là bước bản lề nhằm cung cấp cho mô hình các tín hiệu đầu vào phong phú, giúp mô hình nhận diện được các mẫu hình phức tạp. Các nhóm đặc trưng thời gian và mùa vụ được sử dụng phổ biến bao gồm:

- **Các đặc trưng thời gian cơ bản:** Đây là nhóm các biến được trích xuất trực tiếp từ các mốc thời gian của tập dữ liệu lịch sử, bao gồm thông tin về giờ, ngày trong tuần, tháng và có trạng thái ngày nghỉ lễ. Việc mã hóa các thông tin này giúp mô hình phân biệt được sự khác nhau trong thói quen tiêu thụ năng lượng theo từng khung giờ sinh hoạt, nhận biết được sự sụt giảm tải trong tiêu thụ vào các ngày cuối tuần so với ngày làm việc, cũng như nắm bắt được sự thay đổi nhu cầu sử dụng điện năng theo các tháng trong năm.
- **Các đặc trưng lượng giác:** Các thông tin thời gian khi biểu diễn dưới dạng số nguyên rời rạc thường làm mất đi tính liên tục tự nhiên của chu kỳ (ví dụ: khoảng cách toán học giữa giờ 23 và giờ 0 lớn, dù thực tế chúng liền kề nhau). Để khắc phục vấn đề này, phép biến đổi lượng giác được áp dụng để tạo ra các biến

$\sin_time$

và

$\cos_time$.

Các biến này giúp mô hình hóa tính tuần hoàn trơn tru của thời gian theo các chu kỳ đa dạng như chu kỳ ngày, chu kỳ tuần và chu kỳ năm.

- **Các đặc trưng trễ và thống kê trượt:** Bên cạnh yếu tố thời gian biểu, giá trị của chuỗi ở các bước thời gian trước đó cũng chứa đựng thông tin mang tính dự báo cao. Việc bổ sung các đặc trưng trễ giúp mô hình tận dụng trực tiếp dữ liệu tiêu thụ trong quá khứ gần. Đồng thời, các đại lượng thống kê trượt được tính toán trên một cửa sổ thời gian nhất định (như trung bình trượt hay độ lệch chuẩn trượt) sẽ giúp làm mượt nhiễu, định lượng được xu hướng hiện tại và sự biến động cục bộ của chuỗi dữ liệu đầu vào.

2.3 Các mô hình cơ sở

Trong các nghiên cứu dự báo chuỗi thời gian, việc thiết lập các mô hình cơ sở đóng vai trò thiết yếu. Các mô hình này tuy có cấu trúc toán học đơn giản nhưng lại cung cấp một hệ quy chiếu chuẩn mực. Từ hệ quy chiếu này, người nghiên cứu có thể đánh giá và định lượng được mức độ cải thiện hiệu suất thực sự của các kiến trúc học sâu phức tạp được đề xuất sau đó. Các mô hình cơ sở được lựa chọn để so sánh trong nghiên cứu này bao gồm:

- **Naive forecasting:** Đây là phương pháp dự báo đơn giản nhất, dựa trên giả định rằng giá trị của tương lai sẽ lặp lại chính xác những gì vừa diễn ra trong quá khứ. Dưới góc độ toán học, dự báo cho bước thời gian tiếp theo chính là giá trị quan sát được ở bước thời gian liền trước đó, được biểu diễn qua phương trình

$$\hat{y}_{t+1} = y_t.$$

Đối với chuỗi dữ liệu mang tính chu kỳ mạnh như tiêu thụ điện năng, biến thể *Seasonal Naive* thường được áp dụng, tức là giá trị dự báo sẽ bằng với giá trị của cùng thời điểm ở chu kỳ liền trước (ví dụ: dự báo tải điện lúc 10h sáng ngày mai bằng đúng tải điện lúc 10h sáng hôm nay). Mặc dù không đòi hỏi quá trình huấn luyện phức tạp, Naive forecasting thiết lập một ngưỡng giới hạn hiệu suất tối thiểu mà mọi mô hình nâng cao bắt buộc phải vượt qua.

- **Moving Average:** Mô hình Trung bình trượt ước lượng giá trị tương lai bằng cách tính trung bình cộng của các quan sát thuộc k mốc thời gian có độ dài cố định k

gần nhất. Phương trình dự báo có dạng:

$$\hat{y}_{t+1} = \frac{1}{k} \sum_{i=0}^{k-1} y_{t-i}.$$

Ưu điểm lớn nhất của mô hình này là khả năng làm trơn các nhiễu ngẫu nhiên ngắn hạn của chuỗi dữ liệu. Tuy nhiên, hạn chế của Moving Average là sự phản ứng chậm với những thay đổi đột ngột hoặc các xu hướng tăng/giảm rõ rệt do tính chất trung bình hóa dữ liệu quá khứ.

- **Linear Regression for Time Series:** Mặc dù ban đầu được thiết kế cho dữ liệu mặt cắt ngang, Hồi quy tuyến tính có thể được tinh chỉnh để áp dụng cho bài toán chuỗi thời gian bằng cách chuyển đổi cấu trúc dữ liệu thành dạng học có giám sát. Thay vì sử dụng các biến độc lập thông thường, mô hình sẽ sử dụng các chỉ số thời gian, các đặc trưng trễ, hoặc các biến phân loại được mã hóa (như giờ, ngày) làm các biến đầu vào X_i để dự báo biến mục tiêu y (lượng tiêu thụ điện). Phương trình cơ bản có dạng:

$$\hat{y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n.$$

2.4 Các mô hình có yếu tố mùa vụ

Đặc thù lớn nhất của dữ liệu tiêu thụ điện năng là sự xuất hiện của các chu kỳ lặp lại rõ rệt theo thời gian (ví dụ: chu kỳ ngày đêm, chu kỳ ngày làm việc trong tuần, hoặc chu kỳ theo mùa trong năm). Các mô hình cơ sở thường gặp khó khăn trong việc nắm bắt những dao động có tính chu kỳ này. Do đó, việc áp dụng các mô hình có khả năng tích hợp và xử lý trực tiếp yếu tố mùa vụ là bước tiến quan trọng nhằm nâng cao độ chính xác của dự báo. Hai phương pháp tiêu biểu được xem xét trong nhóm này bao gồm:

- **Mô hình SARIMAX** (*Seasonal Autoregressive Integrated Moving Average with exogenous variables*): SARIMAX là một trong những mô hình thống kê kinh điển và mạnh mẽ nhất trong phân tích chuỗi thời gian. Đây là sự mở rộng toàn diện của mô hình ARIMA, được thiết kế đặc biệt để xử lý đặc tính mùa vụ và cho phép đưa thêm các biến ngoại sinh vào phương trình dự báo. Cấu trúc của SARIMAX được xác định bởi bộ tham số

$$(p, d, q) \times (P, D, Q)_s,$$

trong đó:

- Phần không mang tính mùa vụ bao gồm: bậc tự hồi quy p , bậc sai phân d , và bậc trung bình trượt q .
- Phần mang tính mùa vụ bao gồm: bậc tự hồi quy mùa vụ P , bậc sai phân mùa vụ D , và bậc trung bình trượt mùa vụ Q , với s là chu kỳ mùa vụ (ví dụ: $s = 24$ đối với dữ liệu có tính chu kỳ theo ngày).
- Khả năng tích hợp biến ngoại sinh (X) cho phép mô hình sử dụng thêm các thông tin như nhiệt độ, độ ẩm hoặc trạng thái ngày lễ để giải thích các biến động đột biến của tải điện. Mặc dù có nền tảng toán học vững chắc và khả năng diễn giải cao, SARIMAX thường đòi hỏi quá trình tinh chỉnh tham số phức tạp và có thể gặp giới hạn khi phải mô hình hóa các mối quan hệ phi tuyến tính phức tạp trong dữ liệu lớn.

- **Mô hình XGBoost với kỹ thuật trích xuất đặc trưng thời gian:**

XGBoost (*eXtreme Gradient Boosting*) là một thuật toán học máy dựa trên tập hợp các cây quyết định, nổi tiếng với tốc độ huấn luyện nhanh và hiệu suất dự báo xuất sắc. Bản chất các mô hình dạng cây không tự động nhận biết được thứ tự thời gian hay phép ngoại suy xu hướng như các mô hình thống kê truyền thống. Tuy nhiên, XGBoost có thể trở thành một mô hình dự báo chuỗi thời gian vượt trội khi được kết hợp với kỹ thuật trích xuất đặc trưng chuyên sâu.

Bằng cách chuyển đổi chuỗi thời gian thành bài toán học có giám sát và cung cấp cho XGBoost các biến đầu vào như đặc trưng trễ, đặc trưng thời gian (giờ, ngày, tháng) và đặc biệt là các biến lượng giác để biểu diễn chu kỳ tuần hoàn, mô hình có thể tự động học được các tương quan, tác động phi tuyến và quy luật mùa vụ phức tạp. Điểm mạnh của phương pháp này là khả năng chống chịu tốt với nhiễu, dữ liệu khuyết thiếu và không yêu cầu các giả định ngặt nghèo về phân phối dữ liệu như các mô hình thống kê truyền thống.

2.5 Các mô hình học sâu cho chuỗi thời gian

Trong những năm gần đây, học sâu đã mang lại những bước tiến đột phá trong bài toán dự báo chuỗi thời gian. Các kiến trúc này có khả năng tự động trích xuất các

đặc trưng phi tuyến tính phức tạp mà không cần dựa quá nhiều vào các giả định phân phối ngặt nghèo của phương pháp thống kê truyền thống. Các kiến trúc mạng tiêu biểu được ứng dụng rộng rãi bao gồm:

- **Mạng nơ-ron hồi quy với cơ chế cổng (LSTM và GRU):**

- **LSTM:** Được thiết kế để khắc phục nhược điểm về bài toán suy biến đạo hàm (*vanishing gradient*) của các mạng nơ-ron hồi quy (RNN) truyền thống. Thông qua việc sử dụng trạng thái nhớ tế bào và bộ ba cổng điều khiển (cổng quên, cổng đầu vào, cổng đầu ra), LSTM có khả năng sàng lọc, ghi nhớ hoặc xóa bỏ thông tin trong những khoảng thời gian dài. Khả năng này rất phù hợp để nắm bắt sự phụ thuộc xa trong chuỗi dữ liệu tải điện.
- **GRU:** Là một biến thể tối ưu hóa của LSTM, kết hợp cổng quên và cổng đầu vào thành một cổng cập nhật duy nhất. Cấu trúc tinh gọn này giúp GRU giảm thiểu số lượng tham số, hội tụ nhanh hơn và tiết kiệm tài nguyên tính toán, trong khi vẫn duy trì hiệu suất dự báo tương đương LSTM trong nhiều kịch bản.

- **Các kiến trúc Transformer cho chuỗi thời gian:** Sự ra đời của cơ chế tự chú ý đã tạo ra một thể hệ mô hình mới, cho phép tính toán mức độ liên quan giữa mọi cặp bước thời gian một cách song song. Để khắc phục điểm yếu của Transformer gốc khi áp dụng vào chuỗi thời gian, nhiều biến thể đã được đề xuất:

- **Informer:** Tối ưu hóa cơ chế tính toán thông qua *ProbSparse self-attention*, giúp giảm độ phức tạp từ mức trung bình $O(L^2)$ xuống còn $O(L \log L)$. Điều này giúp mô hình xử lý hiệu quả bài toán dự báo chuỗi dài (*Long-sequence Time-series Forecasting*).
- **Autoformer:** Tích hợp trực tiếp cơ chế phân rã chuỗi thời gian (*decomposition*) thành các thành phần xu hướng và mùa vụ ngay trong lõi mô hình. Đồng thời, mô hình này sử dụng cơ chế *Auto-Correlation* dựa trên lý thuyết tín hiệu thay cho *self-attention* truyền thống.
- **iTransformer:** Đề xuất một góc nhìn “đảo ngược” (*inverted*), trong đó cơ chế attention được áp dụng lên chiều biến số (*variables*) thay vì chiều thời gian

(*time steps*). Kỹ thuật này giúp mô hình nắm bắt tốt hơn mối quan hệ đa biến và nâng cao khả năng tổng quát hóa trên dữ liệu thực tế.

- **Nhóm kiến trúc tiên tiến:** Bên cạnh Transformer, các hướng tiếp cận kết hợp như TimeMixer và xLSTM-Mixer cũng liên tục được phát triển nhằm tối ưu hóa quá trình hòa trộn thông tin:
 - **TimeMixer:** Tận dụng cấu trúc đa tỉ lệ (*multi-scale*) và cơ chế trộn (*mixing*) dữ liệu ở nhiều độ phân giải thời gian khác nhau. Cách tiếp cận này cho phép mô hình đồng thời trích xuất được các đặc điểm động vì mô ngắn hạn và xu hướng vĩ mô dài hạn.
 - **xLSTM-Mixer (Tổng quan):** Là sự giao thoa giữa kiến trúc hồi quy hiện đại xLSTM (với bộ nhớ mở rộng và cơ chế củng cố mạnh mẽ) cùng các khối trộn (*Mixer blocks*). Mô hình mang lại khả năng mở rộng (*scalability*) cao và hiệu suất vượt trội trên các tập dữ liệu chuỗi thời gian có cấu trúc phức tạp.

2.6 Mô hình TimeXer

TimeXer là kiến trúc Transformer được đề xuất tại hội nghị NeurIPS 2024, hướng tới bài toán dự báo chuỗi thời gian có biến ngoại sinh (exogenous variables). Ý tưởng cốt lõi của TimeXer là phối hợp hai cách biểu diễn token khác nhau cho hai loại biến: biến nội sinh (endogenous, tức biến mục tiêu) được biểu diễn theo từng đoạn thời gian (patch), trong khi các biến ngoại sinh được biểu diễn theo từng biến số (variate) theo tinh thần của iTransformer. Hai dòng thông tin này được kết nối thông qua cơ chế chú ý chéo (cross-attention).

2.6.1 Nhúng biến nội sinh theo đoạn (patch embedding)

Chuỗi nội sinh trong cửa sổ nhìn lại độ dài L được chia thành các đoạn không chồng lấn có độ dài P (patch length), thu được $N = \lfloor L/P \rfloor$ đoạn. Mỗi đoạn $\mathbf{x}^{(i)} \in \mathbb{R}^P$ được chiếu tuyến tính lên không gian ẩn $\mathbb{R}^d$ bằng một ma trận chung, sau đó cộng thêm mã vị trí (positional embedding):

$$\mathbf{p}_i = \mathbf{W}_P \mathbf{x}^{(i)} + \mathbf{e}_i, \quad i = 1, \dots, N.$$

Ngoài N token đoạn, mô hình bổ sung một token toàn cục (global token) $\mathbf{g} \in \mathbb{R}^d$ đóng vai trò tổng hợp thông tin toàn chuỗi và làm cầu nối tới nhánh ngoại sinh. Tập token nội sinh do đó có dạng $\{\mathbf{p}_1, \dots, \mathbf{p}_N, \mathbf{g}\}$ gồm $N + 1$ phần tử.

2.6.2 Nhúng biến ngoại sinh theo biến số (variate embedding)

Khác với nhánh nội sinh, mỗi biến ngoại sinh được nén toàn bộ chuỗi quan sát độ dài L thành một token duy nhất theo hướng đảo chiều (inverted). Với C biến ngoại sinh, ta thu được C token, mỗi token là kết quả của một phép chiếu tuyến tính trên trục thời gian:

$$\mathbf{v}_c = \mathbf{W}_V \mathbf{z}_{[t-L+1:t]}^{(c)} + \mathbf{b}, \quad c = 1, \dots, C,$$

trong đó $\mathbf{z}^{(c)}$ là chuỗi của biến ngoại sinh thứ c . Cách biểu diễn này giúp mô hình nắm bắt quan hệ phụ thuộc giữa các biến số, song có đặc điểm quan trọng là toàn bộ biến thiên theo thời gian của mỗi biến ngoại sinh bị nén lại trong một token.

2.6.3 Cơ chế chú ý và luồng thông tin

Bên trong mỗi lớp mã hóa (encoder layer), token nội sinh trước hết tương tác với nhau qua tự chú ý (self-attention) để học cấu trúc thời gian nội tại. Sau đó, token nội sinh (đóng vai trò truy vấn, query) thực hiện chú ý chéo tới tập token ngoại sinh (đóng vai trò khóa và giá trị, key và value):

$$\text{Attn}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V}.$$

Nhờ đó, thông tin từ các biến ngoại sinh được bơm vào biểu diễn nội sinh một cách có chọn lọc. Cuối cùng, các token đoạn được làm phẳng và đưa qua một đầu dự báo tuyến tính (forecast head) để sinh ra véc-tơ dự báo đa bước $\hat{\mathbf{y}} \in \mathbb{R}^H$ với H là tầm dự báo.

2.6.4 Những hạn chế làm cơ sở cho cải tiến

Mặc dù đạt hiệu quả cao, kiến trúc TimeXer gốc bộc lộ một số hạn chế trực tiếp tạo động lực cho các đề xuất cải tiến của nhóm:

- **Hàm mất mát đối xử đồng đều mọi bước dự báo:** TimeXer huấn luyện với sai số toàn phương trung bình, vốn gán trọng số như nhau cho mọi horizon h , bất

chấp phương sai sai số dự báo tăng dần theo h và bất chấp cấu trúc tương quan thời gian của chuỗi. Đây là cơ sở cho cải tiến hàm loss ở Chương 4.

- **Chú ý chéo bỏ qua độ trễ và tương quan động:** Cơ chế cross-attention không tường minh mô hình hóa độ trễ (lag) giữa biến ngoại sinh và biến mục tiêu, trong khi tác động của các yếu tố như nhiệt độ lên phụ tải thường mang tính trễ pha.
- **Mất biến thiên thời gian của biến ngoại sinh:** Việc nén mỗi biến ngoại sinh thành một token đơn làm tiêu biến thông tin biến thiên trong cửa sổ. Hai hạn chế sau là cơ sở cho cơ chế biến ngoại sinh nhận biết độ trễ ở Chương 5.

2.7 Cơ sở lý thuyết về mức độ tương quan thời gian (Time Correlation)

Vì cả hai hướng cải tiến của đề tài đều xoay quanh khái niệm tương quan thời gian, mục này hệ thống hóa các thước đo phụ thuộc được sử dụng xuyên suốt báo cáo.

2.7.1 Hàm tự tương quan và tự tương quan riêng phần

Với một chuỗi dừng $\{y_t\}$, hàm tự tương quan (autocorrelation function, ACF) tại độ trễ k đo mức tương quan tuyến tính giữa chuỗi và chính nó dịch đi k bước:

$$\rho(k) = \frac{\text{Cov}(y_t, y_{t-k})}{\text{Var}(y_t)}.$$

Hàm tự tương quan riêng phần (partial autocorrelation function, PACF) đo tương quan giữa y_t và y_{t-k} sau khi đã loại bỏ ảnh hưởng của các bước trung gian $y_{t-1}, \dots, y_{t-k+1}$. ACF và PACF là công cụ then chốt để nhận diện tính chu kỳ (các đỉnh tại bội số của chu kỳ mùa vụ) và bậc phụ thuộc của chuỗi.

2.7.2 Hệ số tương quan Pearson

Hệ số Pearson giữa hai biến X và Y ,

$$r = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_i (X_i - \bar{X})^2} \sqrt{\sum_i (Y_i - \bar{Y})^2}},$$

chỉ phản ánh quan hệ tuyến tính. Một hạn chế quan trọng là khi quan hệ giữa hai biến mang dạng phi tuyến đối xứng (chẳng hạn quan hệ hình chữ U), hệ số Pearson có thể tiệm cận 0 dù hai biến phụ thuộc chặt chẽ.

2.7.3 Tương quan khoảng cách (distance correlation)

Để khắc phục hạn chế của Pearson, đề tài sử dụng tương quan khoảng cách (distance correlation, dCor). Cho hai mẫu, ký hiệu $a_{ij} = \|X_i - X_j\|$ và $b_{ij} = \|Y_i - Y_j\|$ là các ma trận khoảng cách đôi một. Sau khi trung tâm hóa kép (double centering) để thu được A_{ij} và B_{ij} , hiệp phương sai khoảng cách và tương quan khoảng cách được định nghĩa bởi

$$\text{dCov}^2 = \frac{1}{n^2} \sum_{i,j} A_{ij} B_{ij}, \quad \text{dCor} = \frac{\text{dCov}}{\sqrt{\text{dVar}_X \text{dVar}_Y}}.$$

Tính chất quan trọng của dCor là $\text{dCor}(X, Y) = 0$ khi và chỉ khi X và Y độc lập. Do đó dCor phát hiện được mọi dạng phụ thuộc, kể cả phi tuyến, và là thước đo phù hợp để định lượng mức liên quan của biến ngoại sinh với phụ tải.

2.7.4 Hàm tương quan chéo và độ trễ

Để định lượng quan hệ dẫn dắt theo thời gian giữa một biến ngoại sinh x và mục tiêu y , ta dùng hàm tương quan chéo (cross-correlation function, CCF) theo độ trễ τ :

$$\rho_{xy}(\tau) = \text{Corr}(x_{t-\tau}, y_t).$$

Độ trễ trội $\tau^* = \arg \max_{\tau} |\rho_{xy}(\tau)|$ cho biết biến ngoại sinh chứa thông tin đi trước mục tiêu bao nhiêu bước. Trong đề tài, để tránh bị nhiễu bởi tính đồng mùa vụ, CCF và dCor đều được tính trên phần dư sau khi khử thành phần mùa vụ theo giờ-trong-tuần (168 trạng thái), bảo đảm mối liên hệ đo được phản ánh phụ thuộc thực chất chứ không phải sự trùng pha của hai chu kỳ.


CHƯƠNG 3

TIỀN XỬ LÝ DỮ LIỆU

3.1 Khảo sát và mô tả dữ liệu

Đề tài sử dụng bộ dữ liệu công khai về nhu cầu điện năng và thời tiết của Tây Ban Nha trong giai đoạn 2015–2018 (nguồn dữ liệu vận hành lưới điện ENTSO-E kết hợp dữ liệu thời tiết OpenWeather). Đây là dữ liệu ở cấp quốc gia, ghi nhận theo tần suất một giờ, với biến mục tiêu là tổng phụ tải điện thực tế của hệ thống (*total load actual*), đơn vị MW. Sau khi ghép nối và làm sạch, chuỗi có độ phân giải giờ liên tục từ ngày 31/12/2014 đến 31/12/2018, tổng cộng 35 064 quan sát.

Bên cạnh phụ tải, dữ liệu cung cấp các biến ngoại sinh về thời tiết được tổng hợp từ các thành phố lớn, gồm: nhiệt độ (*temp*, °C), độ ẩm (*humidity*), áp suất (*pressure*), tốc độ gió (*wind_speed*) và độ che phủ mây (*clouds_all*). Các biến này là đầu vào tự nhiên cho nhánh ngoại sinh của TimeXer. Hình 3.1 minh họa đặc điểm của chuỗi phụ tải: ở quy mô năm xuất hiện dao động mùa rõ rệt, còn ở quy mô tuần thể hiện chu kỳ ngày đêm và chu kỳ ngày làm việc trong tuần.



Hình 3.1: Phụ tải điện Tây Ban Nha: trung bình ngày toàn giai đoạn (trên) và chi tiết theo giờ trong hai tuần mẫu (dưới).

3.2 Kiểm tra chất lượng dữ liệu

Trước khi đưa vào mô hình, dữ liệu được kiểm tra và xử lý các vấn đề chất lượng phổ biến:

- **Giá trị khuyết:** Chuỗi phụ tải gốc tồn tại một số ít quan sát khuyết (cỡ vài chục điểm trên tổng số hơn ba mươi lăm nghìn). Do tỉ lệ khuyết rất thấp và chuỗi có tính liên tục cao theo thời gian, các điểm khuyết được nội suy theo thời gian (*time interpolation*) nhằm bảo toàn tính trơn của chuỗi.
- **Trùng lặp và mốc thời gian:** Các bản ghi trùng mốc thời gian được loại bỏ; trục thời gian được chuẩn hóa về múi giờ thống nhất và sắp xếp tăng dần để bảo đảm tính tuần tự.
- **Giá trị bất thường:** Các giá trị ngoại lai cực đoan được rà soát trên cơ sở phân phối của từng biến. Do phụ tải điện ở cấp hệ thống biến thiên trong biên độ sinh lý hợp lý, nghiên cứu giữ nguyên các dao động thực và chỉ can thiệp vào các điểm lỗi ghi nhận rõ ràng.


Kết quả của khâu này là tập dữ liệu sạch theo giờ (*clean_hourly*) không còn giá trị khuyết, làm nền tảng cho các bước trích xuất đặc trưng và phân tích tương quan.

3.3 Trích xuất đặc trưng (Feature Engineering)

Nhằm cung cấp tín hiệu mùa vụ phong phú cho mô hình, nghiên cứu trích xuất hai nhóm đặc trưng thời gian từ mốc thời gian của mỗi quan sát:

- **Đặc trưng lịch cơ bản:** giờ trong ngày, ngày trong tuần, tháng và chỉ báo cuối tuần. Các biến này giúp mô hình phân biệt thói quen tiêu thụ theo khung giờ, theo ngày làm việc và theo mùa.
- **Đặc trưng lượng giác:** mỗi chu kỳ thời gian được biểu diễn bằng cặp sin-cos để bảo toàn tính tuần hoàn trọn (giờ trong ngày, ngày trong tuần, ngày trong năm), khắc phục hiện tượng đứt gãy khi mã hóa thời gian dưới dạng số nguyên rời rạc.

Hình 3.2 cho thấy hai chu kỳ chủ đạo của phụ tải: đường cong theo giờ trong ngày có dạng hai đỉnh (buổi trưa và buổi tối), còn phụ tải ngày làm việc cao hơn rõ rệt so với cuối tuần. Đây là cơ sở để mô hình hóa mùa vụ và cũng định hướng chu kỳ $s = 24$ cho các phân tích về sau.




Hình 3.2: Cấu trúc mùa vụ của phụ tải: trung bình theo giờ trong ngày (trái) và theo ngày trong tuần (phải).

3.4 Phân tích tương quan thời gian

Phân tích ACF và PACF của phụ tải (Hình 3.3) làm lộ rõ cấu trúc phụ thuộc thời gian. ACF suy giảm chậm và xuất hiện các đỉnh tuần hoàn tại bội số của 24 giờ cùng


đỉnh mạnh tại 168 giờ, phản ánh đồng thời chu kỳ ngày và chu kỳ tuần. PACF tắt nhanh sau một vài độ trễ đầu, gợi ý một cấu trúc tự hồi quy bậc thấp chi phối phần phụ thuộc ngắn hạn. Hai quan sát này trực tiếp định hình thiết kế trọng số cho hàm loss ở Chương 4: phương sai sai số dự báo và mức tương quan giữa các bước thời gian không đồng nhất, do đó việc gán trọng số đồng đều cho mọi horizon là chưa tối ưu.



Hình 3.3: ACF (trái) và PACF (phải) của phụ tải. Đường nét đứt là dải ý nghĩa $\pm 1.96/\sqrt{N}$; các đường dọc đánh dấu chu kỳ ngày (24) và tuần (168).

Về tính dừng, kiểm định ADF trên chuỗi phụ tải cho thống kê rất âm, bác bỏ giả thuyết tồn tại nghiệm đơn vị; tuy nhiên chuỗi vẫn mang thành phần mùa vụ rất định mạnh. Hai kết quả này không mâu thuẫn vì chúng kiểm tra hai tính chất khác nhau: không có nghiệm đơn vị không đồng nghĩa với việc đã loại bỏ mùa vụ. Vì vậy, thay cho phép sai phân mùa vụ ∇_{24} (vốn dễ gây quá sai phân và sinh tự tương quan âm nhân tạo), nghiên cứu khử mùa vụ bằng cách trừ trung bình theo trạng thái giờ-trong-tuần khi cần phân tích phần dư.

Hình 3.4 minh họa một điểm phương pháp luận quan trọng cho nhánh ngoại sinh ở Chương 5: ở độ phân giải giờ, tương quan Pearson giữa nhiệt độ và phụ tải rất yếu (xấp xỉ 0.205) do bị nhiễu bởi chu kỳ ngày; nhưng khi tổng hợp về độ phân giải ngày và xét đại lượng phi tuyến $|temp - 17|$, quan hệ hình chữ U với phụ tải trở nên rõ rệt (Pearson xấp xỉ 0.292). Điều này cho thấy thước đo tuyến tính đánh giá thấp vai trò của nhiệt độ, và là động cơ để sử dụng tương quan khoảng cách trong cơ chế chọn lọc biến ngoại sinh.



Hình 3.4: Quan hệ nhiệt độ–phụ tải: theo giờ với Pearson yếu (trái) và theo ngày với đặc trưng phi tuyến $|temp - 17|$ cho quan hệ mạnh hơn (phải).

3.5 Chuẩn hóa dữ liệu

Toàn bộ các biến được chuẩn hóa về thang điểm z bằng *StandardScaler*. Một nguyên tắc bắt buộc được tuân thủ nghiêm ngặt là chỉ ước lượng tham số chuẩn hóa (trung bình và độ lệch chuẩn) trên tập huấn luyện, sau đó áp dụng nguyên vẹn cho tập kiểm định và kiểm thử, nhằm tránh rò rỉ thông tin (*data leakage*) từ tương lai vào quá khứ. Ngoài lớp chuẩn hóa tổng thể này, bản thân mô hình TimeXer còn áp dụng chuẩn hóa theo từng cửa sổ (*instance normalization*) để khử thành phần mức và độ phân tán cục bộ, giúp ổn định quá trình huấn luyện trên chuỗi phi dừng.

3.6 Chia tập dữ liệu

Do bản chất tuần tự của dữ liệu, việc chia tập được thực hiện theo thời gian (*chronological split*) theo tỉ lệ xấp xỉ 70/15/15, tuyệt đối không xáo trộn ngẫu nhiên để bảo toàn trật tự nhân quả. Cụ thể, tập huấn luyện gồm 24 544 quan sát (đến 19/10/2017), tập kiểm định gồm 5 260 quan sát, và tập kiểm thử gồm 5 260 quan sát (đến 31/12/2018). Với cấu hình cửa sổ nhìn lại $L = 168$ giờ (bảy ngày) và tầm dự báo $H = 24$ giờ, mỗi tập được cắt thành các mẫu theo kỹ thuật cửa sổ trượt đã trình bày ở Chương 2.

CHƯƠNG 4

ĐỀ XUẤT CẢI TIẾN: HÀM LOSS DỰA TRÊN MỨC ĐỘ TƯƠNG QUAN THỜI GIAN

4.1 Phân tích hạn chế của loss function truyền thống trong TimeXer

Trong dự báo đa bước, TimeXer (và phần lớn các mô hình học sâu) được huấn luyện bằng sai số toàn phương trung bình trên toàn bộ tầm dự báo:

$$\mathcal{L}_{\text{MSE}} = \frac{1}{H} \sum_{h=1}^H (\hat{y}_{t+h} - y_{t+h})^2.$$

Hàm này gán trọng số đồng đều $1/H$ cho mọi bước dự báo. Tuy nhiên, hai đặc điểm của bài toán cho thấy cách đối xử đồng đều là chưa tối ưu:

- **Phương sai sai số không đồng nhất theo horizon:** Theo lý thuyết dự báo, phương sai của sai số dự báo h bước tăng dần theo h . Sai số ở các bước xa vốn khó kiểm soát và nhiều hơn; việc dồn trọng số như nhau khiến mô hình tiêu tốn năng lực để khớp các bước xa nhiều, thay vì củng cố các bước gần vốn có khả năng dự báo cao hơn.
- **Bỏ qua cấu trúc tương quan thời gian:** MSE coi sai số tại các bước là độc lập, trong khi sai số dự báo ở các bước liên kế có tương quan chéo (do cùng chịu chi phối bởi cú sốc gần thời điểm dự báo). Một hàm loss khai thác cấu trúc hiệp phương sai sai số sẽ phản ánh trung thực hơn hình học của bài toán.

4.2 Ý tưởng đề xuất:

Time-Correlation Weighted Loss

Ý tưởng cốt lõi là thay sai số đồng đều bằng sai số có trọng số, trong đó trọng số được suy ra một cách có nguyên tắc từ chính cấu trúc tương quan thời gian của chuỗi, thay vì gán theo cảm tính.


Cụ thể, từ phần dư phụ tải đã khử mùa vụ trên tập huấn luyện, nghiên cứu ước lượng một mô hình tự hồi quy $AR(p)$ bằng phương trình Yule–Walker, rồi chuyển sang biểu diễn trung bình trượt vô hạn $MA(\infty)$ với các trọng số $\{\psi_k\}$. Khi đó, sai số dự báo h bước là tổ hợp của các cú sốc ε , và hiệp phương sai sai số giữa hai bước i, j có dạng

$$\Sigma_\psi[i, j] = \sigma_\varepsilon^2 \sum_{k=0}^{\min(i, j)} \psi_k \psi_{k+|i-j|}.$$

Phương sai sai số tại bước h chính là phần tử đường chéo $\Sigma_\psi[h, h] = \sigma_\varepsilon^2 \sum_{k < h} \psi_k^2$, là một hàm tăng theo h . Từ đó, nghiên cứu định nghĩa trọng số nghịch phương sai:

$$w_h^{\text{invvar}} = \frac{1}{\Sigma_\psi[h, h]}, \quad (\text{chuẩn hóa sao cho trung bình bằng 1}).$$

Vì phương sai sai số tăng theo h , trọng số w_h^{invvar} giảm đơn điệu theo horizon, tức là mô hình được khuyến khích ưu tiên các bước gần có độ tin cậy cao hơn. Hình 4.1 (trái) minh họa hồ sơ trọng số giảm đơn điệu thu được trên dữ liệu thực.



Hình 4.1: Trọng số loss suy từ cấu trúc tương quan: trọng số nghịch phương sai theo horizon (trái) và ma trận chính xác W sau khi shrinkage để không chế số điều kiện (phải).

Hàm mất mát có trọng số (*Weighted MSE*) được định nghĩa bởi

$$\mathcal{L}_W = \frac{1}{H} \sum_{h=1}^H w_h^{\text{invvar}} (\hat{y}_{t+h} - y_{t+h})^2.$$

Một thiết kế quan trọng là khi mọi trọng số bằng nhau, $\mathcal{L}_W$ thu về đúng $\mathcal{L}_{\text{MSE}}$; nói cách khác, MSE là trường hợp đặc biệt lồng nhau (nested) của hàm loss đề xuất, bảo đảm tính so sánh công bằng trong ablation.

4.3 Phương án tích hợp vào kiến trúc TimeXer

Hàm loss đề xuất thay thế trực tiếp hàm mục tiêu trong quá trình huấn luyện mà không làm thay đổi kiến trúc xuôi (forward) của TimeXer; do đó nó trực giao với các cải tiến về mặt kiến trúc và có thể kết hợp linh hoạt. Bên cạnh biến thể trọng số đường chéo, nghiên cứu xét thêm dạng tổng quát hơn khai thác toàn bộ ma trận hiệp phương sai sai số, gọi là hàm loss cấu trúc tương quan (*CorrStruct Loss*):

$$\mathcal{L}_{\text{corr}} = \frac{1}{H} \mathbf{e}^\top W \mathbf{e}, \quad \mathbf{e} = \hat{\mathbf{y}} - \mathbf{y},$$

với W là ma trận chính xác (precision) thu từ nghịch đảo của Σ_ψ . Vì ma trận hiệp phương sai sai số thường có số điều kiện lớn, việc nghịch đảo trực tiếp dễ gây bất ổn và sụp gradient. Để khắc phục, nghiên cứu áp dụng kỹ thuật co rút về đường chéo (*diagonal shrinkage*): pha trộn Σ_ψ với một ma trận đường chéo theo hệ số α cho tới khi số điều kiện của ma trận kết quả không vượt quá một ngưỡng định trước (đặt là 150). Trên dữ liệu thực, số điều kiện được kéo từ mức trên một nghìn về dưới 150 với $\alpha \approx 0.08$, giúp ổn định quá trình huấn luyện (Hình 4.1, phải). Khi W là ma trận đơn vị, $\mathcal{L}_{\text{corr}}$ cũng thu về MSE, duy trì tính lồng nhau.

4.4 Các phương án loss thay thế để so sánh (ablation)

Để đánh giá khách quan, nghiên cứu xây dựng ba biến thể hàm loss dùng chung một quy trình huấn luyện:

- **MSE:** hàm cơ sở, gán trọng số đồng đều cho mọi horizon.
- **Weighted (nghịch phương sai):** dùng trọng số w_h^{invvar} giảm đơn điệu suy từ Σ_ψ .
- **CorrStruct:** dùng toàn bộ ma trận chính xác W đã co rút.

Nguồn trọng số được tính một lần trên tập huấn luyện và lưu lại để tái sử dụng, bảo đảm tính tái lập. Toàn bộ các biến thể đều thỏa mãn điều kiện lồng nhau với MSE, điều kiện cần để phép so sánh ablation phản ánh đúng đóng góp của thành phần trọng số.

CHƯƠNG 5

XÂY DỰNG MÔ HÌNH

Để đánh giá khách quan hiệu quả của các cải tiến đề xuất, nghiên cứu xây dựng một hệ thống mô hình phân tầng, từ các mô hình cơ sở đơn giản tới mô hình TimeXer cải tiến. Tất cả các mô hình được huấn luyện và đánh giá trên cùng một quy trình chia tập và cùng bộ chỉ số.

5.1 Nhóm mô hình Baseline

Nhóm cơ sở thiết lập ngưỡng hiệu suất tối thiểu, bao gồm: dự báo ngây thơ theo mùa (*Seasonal Naive*, lấy giá trị cùng thời điểm ở chu kỳ ngày liền trước), trung bình trượt (*Moving Average*) và hồi quy tuyến tính trên các đặc trưng thời gian. Như đã trình bày ở Chương 2, các mô hình này tuy đơn giản nhưng cung cấp hệ quy chiếu cần thiết: mọi kiến trúc phức tạp đều phải vượt qua ngưỡng do chúng thiết lập mới được xem là có giá trị thực tiễn.

5.2 Nhóm mô hình có yếu tố mùa vụ

Nhóm này gồm SARIMAX và XGBoost kết hợp trích xuất đặc trưng thời gian. SARIMAX với cấu trúc $(p, d, q) \times (P, D, Q)_s$ và $s = 24$ khai thác trực tiếp tính mùa vụ ngày, đồng thời cho phép đưa các biến ngoại sinh thời tiết vào phương trình. XGBoost biến bài toán chuỗi thời gian thành bài toán học có giám sát thông qua các đặc trưng trễ và đặc trưng lượng giác, qua đó nắm bắt các quan hệ phi tuyến và mùa vụ phức tạp.

Mô hình	MAE	MSE	RMSE
SARIMAX(1, 1, 1)x(1, 0, 1, 24)	0.1804	0.0516	0.2272
XGBoost	0.2980	0.1965	0.4433

Bảng 5.1: Sai số của các mô hình SARIMAX và XGBoost trên dữ liệu chuẩn hóa

5.3 Nhóm mô hình Deep Learning

Nhóm học sâu hồi quy gồm LSTM và GRU, đại diện cho khả năng mô hình hóa phụ thuộc dài hạn thông qua cơ chế cổng. Đây là nhóm trung gian giữa các mô hình thống kê và kiến trúc Transformer, cho phép định vị mức cải thiện mà TimeXer mang lại.

Mô hình	MAE	MSE	RMSE
LSTM	0.2753	0.1747	0.4179
GRU	0.2630	0.1672	0.4089

Bảng 5.2: Sai số của các mô hình trên dữ liệu chuẩn hóa

5.4 Mô hình TimeXer (gốc)

TimeXer gốc được triển khai theo kiến trúc đã mô tả ở Chương 2, đóng vai trò mô hình lõi và là mốc so sánh trực tiếp cho các cải tiến. Cấu hình sử dụng xuyên suốt: cửa sổ nhìn lại $L = 168$ giờ, tầm dự báo $H = 24$ giờ, độ dài đoạn $P = 24$ (tương ứng 7 đoạn cộng một token toàn cục), số chiều ẩn $d = 512$, số đầu chú ý bằng 8, số lớp mã hóa bằng 2. Biến mục tiêu là phụ tải, các biến thời tiết và đặc trưng thời gian đóng vai trò ngoại sinh. Mô hình được huấn luyện ở chế độ đa biến đầu vào, đơn biến đầu ra (*multivariate-to-single*).

5.5 Mô hình TimeXer cải tiến (đề xuất của nhóm)

Mô hình cải tiến tích hợp hai thành phần trực giao: (i) cơ chế biến ngoại sinh nhận biết độ trễ và chọn lọc theo tương quan phi tuyến (tác động lên kiến trúc xuôi), và (ii) hàm loss có trọng số tương quan đã trình bày ở Chương 4 (tác động lên hàm mục tiêu). Vì trực giao nên hai thành phần có thể bật/tắt độc lập, tạo điều kiện cho phân tích ablation giai thừa ở Chương 6.


5.5.1 Pha 1: Lập hồ sơ liên quan phi tuyến theo độ trễ

Mục tiêu của Pha 1 là, từ dữ liệu huấn luyện, tự động xác định mỗi biến ngoại sinh liên quan đến phụ tải ở mức độ nào và tại độ trễ nào, mà không cần tri thức miền cài cứng. Trên phần dư đã khử mùa vụ theo giờ-trong-tuần, nghiên cứu tính hồ sơ tương quan khoảng cách theo độ trễ:

$$R_j(\tau) = \text{dCor}(\tilde{x}_{t-\tau}^{(j)}, \tilde{y}_t), \quad \tau = 0, 1, \dots, L_{\max},$$


với $\tilde{x}^{(j)}$ và $\tilde{y}$ là phần dư của biến ngoại sinh thứ j và của phụ tải. Cửa sổ độ trễ $L_{\max}$ được đặt bằng một chu kỳ mùa vụ (24 giờ) thay vì một hằng số tùy ý, bảo đảm tính tổng quát giữa các bộ dữ liệu. Với mỗi biến, ta trích độ trễ trội $\tau_j^* = \arg \max_{\tau} R_j(\tau)$ và điểm liên quan $R_j^* = R_j(\tau_j^*)$.

Việc dùng dCor thay cho hệ số Pearson là lựa chọn then chốt. Hình 5.1 so sánh trực tiếp hai thước đo trên phần dư đã khử mùa vụ: với biến nhiệt độ, Pearson gần như bằng 0 (xấp xỉ 0.001) trong khi dCor đạt 0.164, tức là thước đo tuyến tính bỏ sót gần như hoàn toàn vai trò của nhiệt độ do quan hệ hình chữ U, còn dCor phục hồi đúng mức liên quan này một cách tự động.



Hình 5.1: So sánh mức liên quan tại độ trễ 0 đo bằng Pearson tuyến tính và dCor phi tuyến (phần dư đã khử mùa vụ). dCor phục hồi vai trò của nhiệt độ mà Pearson bỏ sót.

Hình 5.2 trình bày hồ sơ $R_j(\tau)$ đầy đủ. Nhiệt độ là biến ngoại sinh trội rõ rệt ($R^* \approx 0.172$), vượt xa các biến còn lại (đều dưới 0.10). Bảng 5.3 tổng hợp prior thu được.



Hình 5.2: Hồ sơ tương quan khoảng cách theo độ trễ giữa từng biến ngoại sinh và phụ tải. Điểm tô đậm là độ trễ trội τ_j^* của mỗi biến.

Bảng 5.3: Hồ sơ liên quan ngoại sinh thu được ở Pha 1 (trên tập huấn luyện).

Biến ngoại sinh	Độ trễ trội τ^* (giờ)	Điểm liên quan R^*
temp	23	0.172
wind_speed	20	0.094
humidity	16	0.067
pressure	15	0.063
clouds_all	22	0.053

5.5.2 Pha 2: Căn độ trễ và cổng liên quan học được

Pha 2 đưa prior thu được vào kiến trúc dưới dạng một mô-đun tiền xử lý đặt trước nhánh nhúng ngoại sinh của TimeXer, gồm hai phép biến đổi trên các kênh ngoại sinh:

- **Căn độ trễ nhân quả:** mỗi kênh ngoại sinh j được dịch đi τ_j^* bước về quá khứ (xử lý biên bằng lấp giá trị đầu) để căn pha thông tin dẫn dắt về gốc dự báo. Phép căn lag là cần thiết vì nhúng đảo chiều của TimeXer dùng chung một phép chiếu thời gian cho mọi biến, nên không thể tự học dịch pha riêng cho từng kênh.
- **Cổng liên quan học được:** mỗi kênh được nhân với một cổng $g_j = \sigma(\theta_j) \in (0, 1)$, trong đó θ_j là tham số học được, khởi tạo theo prior R_j^* sao cho biến càng liên quan có cổng khởi đầu càng lớn. Cổng đóng vai trò lọc tín hiệu theo tương quan:

biến ngoại sinh ít liên quan bị nén lại, tương tự nguyên lý chỉ giữ tín hiệu hữu ích nhưng thực hiện theo tương quan phi tuyến thay vì phân rã dải tần. Vì θ_j học được, gradient của hàm dự báo là trọng tài cuối cùng: prior chỉ là điểm khởi đầu, mô hình có thể điều chỉnh lại.

Một tính chất thiết kế quan trọng là khi tắt cả hai phép biến đổi ($g_j \equiv 1$ và $\tau_j^* \equiv 0$), mô-đun trở thành ánh xạ đồng nhất và mô hình thu về đúng TimeXer gốc. Tính lồng nhau này bảo đảm rằng chênh lệch đo được trong ablation phản ánh thuần túy đóng góp của cơ chế ngoại sinh.

5.5.3 Mô hình kết hợp

Mô hình cải tiến đầy đủ kết hợp cơ chế ngoại sinh XCorr-Lag với hàm loss có trọng số tương quan. Do hai thành phần trực giao, nghiên cứu khảo sát toàn bộ tổ hợp của chúng ở Chương 6 nhằm tách bạch đóng góp riêng lẻ và hiệu ứng tương tác.

CHƯƠNG 6

THỰC NGHIỆM VÀ ĐÁNH GIÁ

6.1 Thiết lập thực nghiệm

Toàn bộ thực nghiệm được thực hiện trên nền tảng Google Colab với GPU T4, sử dụng PyTorch. Cấu hình mô hình và dữ liệu tuân theo Chương 5: $L = 168$, $H = 24$, $P = 24$, $d = 512$. Quy trình huấn luyện dùng thuật toán tối ưu Adam với tốc độ học khởi đầu 10^{-4} , bộ điều chỉnh tốc độ học theo nguyên lý giảm khi chững (*ReduceLROnPlateau*, hệ số 0.5), cắt chuẩn gradient ở ngưỡng 1.0 và dừng sớm (*early stopping*) theo sai số trên tập kiểm định.

Một nguyên tắc phương pháp luận được tuân thủ nghiêm ngặt là **đánh giá đa hạt giống ngẫu nhiên** (*multi-seed*): mỗi cấu hình được huấn luyện lại với ba hạt giống độc lập, và kết quả báo cáo dưới dạng trung bình kèm độ lệch chuẩn. Như sẽ thấy trong phần phân tích ablation, nguyên tắc này là thiết yếu vì kết luận từ một hạt giống đơn lẻ có thể bị đảo ngược.

6.2 Các chỉ số đánh giá

Hiệu năng được đo bằng ba chỉ số sai số chuẩn trên tập kiểm thử:

$$\text{MAE} = \frac{1}{n} \sum |\hat{y} - y|, \quad \text{MSE} = \frac{1}{n} \sum (\hat{y} - y)^2, \quad \text{RMSE} = \sqrt{\text{MSE}}.$$

Các chỉ số được tính trên thang chuẩn hóa để so sánh nội bộ, đồng thời được giải chuẩn về đơn vị MW (nhân với độ lệch chuẩn của phụ tải trên tập huấn luyện, $\sigma_{\text{load}} \approx 4536$ MW) để diễn giải thực tiễn.

6.3 Bảng so sánh kết quả tổng hợp

Bảng 6.1 trình bày kết quả ablation giai thừa 2×2 giữa hai trục cải tiến: cơ chế ngoại sinh (tắt/bật) và hàm loss (MSE/Weighted), mỗi ô trung bình trên ba hạt giống.

Bảng 6.1: Kết quả ablation 2×2 trên tập kiểm thử (thang chuẩn hóa), trung bình $\pm$ độ lệch chuẩn trên ba hạt giống. Cấu hình *baseline+mse* chính là TimeXer gốc.

Cơ chế ngoại sinh	Hàm loss	MAE	MSE	RMSE
baseline	mse	0.2840 ± 0.0064	0.1732 ± 0.0044	0.4161 ± 0.0052
baseline	weighted	0.2651 ± 0.0064	0.1598 ± 0.0034	0.3997 ± 0.0043
xcorr_lag	mse	0.2619 ± 0.0124	0.1629 ± 0.0081	0.4035 ± 0.0100
xcorr_lag	weighted	0.2542 ± 0.0053	0.1556 ± 0.0041	0.3945 ± 0.0052


Mô hình kết hợp *xcorr_lag+weighted* đạt kết quả tốt nhất trên cả ba chỉ số, giảm 10.2% MSE và 10.5% MAE so với TimeXer gốc. Bảng 6.2 quy đổi sang đơn vị MW.

Bảng 6.2: Kết quả giải chuẩn về đơn vị MW ($\sigma_{\text{load}} \approx 4536$ MW; phụ tải trung bình $\approx 28\,553$ MW).


Cơ chế ngoại sinh	Hàm loss	MAE (MW)	RMSE (MW)	MAE/trung bình
baseline	mse	1288	1888	4.51%
baseline	weighted	1203	1813	4.21%
xcorr_lag	mse	1188	1830	4.16%
xcorr_lag	weighted	1153	1790	4.04%

6.4 Trực quan hóa kết quả

Hình 6.1 trực quan hóa MAE và MSE của bốn cấu hình kèm thanh sai số độ lệch chuẩn, còn Hình 6.2 biểu diễn mức giảm MSE tương đối so với TimeXer gốc. Có thể thấy cả hai trực cải tiến đều kéo sai số xuống, và cấu hình kết hợp đạt đáy thấp nhất với độ lệch chuẩn nhỏ nhất.



Hình 6.1: So sánh MAE (phải) và MSE (trái) giữa bốn cấu hình, trung bình $\pm$ độ lệch chuẩn trên ba hạt giống.



Hình 6.2: Mức giảm MSE tương đối của từng cấu hình so với TimeXer gốc (*baseline+mse*).


6.5 Phân tích ablation

Phân tích theo từng hạt giống (các hạt giống được dùng chung nên cho phép so sánh theo cặp) làm lộ rõ những kết luận mà giá trị trung bình đơn thuần che giấu:

- **Hàm loss có trọng số là cải tiến đáng tin cậy:** so với TimeXer gốc, biến thể Weighted giảm MSE ở cả ba hạt giống (trung bình -0.0134), đồng thời có độ phân tán nhỏ.
- **Cơ chế ngoại sinh đơn lẻ kém ổn định:** cấu hình *xcorr_lag+mse* chỉ cải thiện ở hai trên ba hạt giống; tại hạt giống 43 nó còn kém hơn TimeXer gốc, và độ lệch chuẩn lớn gần gấp đôi các cấu hình khác (Hình 6.3). Đây chính là minh chứng cho

tính thiết yếu của đánh giá đa hạt giống: nếu chỉ chạy hạt giống 42, cơ chế ngoại sinh sẽ bị kết luận sai là cải tiến mạnh nhất.

- **Kết hợp vừa tốt nhất vừa ổn định nhất:** cấu hình $xcorr_lag+weighted$ thắng ở cả ba hạt giống với độ lệch chuẩn rất nhỏ (0.0014). Đáng chú ý, hàm loss có trọng số đóng vai trò ổn định hóa cơ chế ngoại sinh: độ lệch chuẩn MSE giảm từ 0.0081 ($xcorr_lag+mse$) xuống 0.0041 khi kết hợp.
- **Tương tác dưới-cộng-tính:** tổng lợi ích riêng lẻ của hai cải tiến (0.0236 về MSE) lớn hơn lợi ích của tổ hợp (0.0175), cho thấy hai hướng khai thác một phần thông tin chung. Dù vậy, tổ hợp vẫn là cấu hình thắng rõ rệt và an toàn nhất.



Hình 6.3: MSE theo từng hạt giống. Cấu hình $xcorr_lag+mse$ biến động mạnh (tại hạt giống 43 kém hơn TimeXer gốc), trong khi tổ hợp $xcorr_lag+weighted$ ổn định ở cả ba hạt giống.

6.6 Phân tích định tính

Khảo sát đường dự báo 24 giờ so với giá trị thực cho thấy mô hình bám sát đúng hình dạng chu kỳ ngày, nắm bắt được cả đỉnh và đáy của phụ tải. Hạn chế định tính chủ yếu là xu hướng dự báo thấp hơn thực tế (*under-prediction*) tại các điểm cực trị về biên độ, kèm một độ trễ pha nhẹ tại các điểm uốn. Quan sát này gợi ý hướng tinh chỉnh tiếp theo về xử lý biên độ ở các thời điểm phụ tải cực đại và cực tiểu.

Về cổng liên quan học được, sau huấn luyện, cổng của nhiệt độ duy trì giá trị cao nhất trong các biến ngoại sinh, nhất quán với prior dCor ở Pha 1. Điều này xác nhận

rằng cơ chế đề xuất không chỉ là một lớp tham số tự do mà thực sự học được cấu trúc liên quan phù hợp với bản chất vật lý của bài toán phụ tải–thời tiết.

CHƯƠNG 7

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1 Kết quả đạt được

Đề tài đã xây dựng một pipeline dự báo phụ tải điện năng hoàn chỉnh trên bộ dữ liệu Tây Ban Nha 2015–2018, từ làm sạch dữ liệu, trích xuất đặc trưng, phân tích tương quan thời gian đến huấn luyện và đánh giá mô hình. Trên nền tảng TimeXer, nhóm đề xuất và hiện thực hóa hai cải tiến trực giao:

- **Hàm loss có trọng số tương quan thời gian:** trọng số nghịch phương sai suy từ cấu trúc hiệp phương sai số dự báo, giảm đơn điệu theo horizon. Cải tiến này cho cải thiện ổn định trên cả ba hạt giống.
- **Cơ chế biến ngoại sinh XCorr-Lag:** tự động lập hồ sơ liên quan phi tuyến theo độ trễ bằng tương quan khoảng cách, kết hợp căn lag nhân quả và cổng liên quan học được. Cơ chế này độc lập với bộ dữ liệu và phục hồi đúng vai trò phi tuyến của nhiệt độ mà thước đo tuyến tính bỏ sót.

Khi kết hợp, mô hình cải tiến đạt MSE 0.1556 và MAE 0.2542 trên thang chuẩn hóa (tương đương MAE ≈ 1153 MW, xấp xỉ 4.0% phụ tải trung bình), giảm 10.2% MSE so với TimeXer gốc, đồng thời là cấu hình ổn định nhất giữa các hạt giống.

7.2 Hạn chế của đề tài

Nghiên cứu còn một số hạn chế cần ghi nhận một cách trung thực:

- Cơ chế biến ngoại sinh khi dùng riêng với MSE cho hiệu quả phụ thuộc hạt giống, chỉ ổn định khi kết hợp với hàm loss có trọng số; cần thêm số hạt giống để khẳng định vững chắc hơn.
- Tương tác giữa hai cải tiến mang tính dưới-cộng-tính, cho thấy chúng khai thác một phần thông tin chung chứ chưa hoàn toàn bổ trợ.

- Đánh giá hiện tập trung trên một bộ dữ liệu và một tầm dự báo $H = 24$; tính tổng quát qua các bộ dữ liệu và tầm dự báo khác chưa được kiểm chứng đầy đủ.
- Về định tính, mô hình còn xu hướng dự báo thấp ở các điểm cực trị về biên độ.

7.3 Hướng phát triển

Từ các hạn chế trên, đề tài đề xuất các hướng phát triển tiếp theo:

- Mở rộng kiểm chứng trên các bộ dữ liệu chuẩn khác (chẳng hạn EPF, ECL) và nhiều tầm dự báo, nhằm khẳng định tính tổng quát của cơ chế đề xuất.
- Khảo sát cổng liên quan phụ thuộc thời gian hoặc giữ biến thiên thời gian của biến ngoại sinh theo đoạn, thay vì nén thành token đơn, để xử lý triệt để hơn hạn chế của TimeXer.
- Nghiên cứu các thước đo phụ thuộc thay thế (mutual information) và các phương án trọng số loss khác, đồng thời phân tích sâu hiệu ứng tương tác giữa hai trục cải tiến.
- Bổ sung thành phần hiệu chỉnh biên độ tại các thời điểm phụ tải cực đại và cực tiểu để khắc phục hiện tượng dự báo thấp.

Tóm lại, đề tài đã chứng minh rằng việc khai thác cấu trúc tương quan thời gian một cách có nguyên tắc, cả ở hàm mục tiêu lẫn ở cách tích hợp biến ngoại sinh, mang lại cải thiện đo lường được và ổn định cho mô hình TimeXer trong bài toán dự báo phụ tải điện năng. Quan trọng không kém, quá trình thực nghiệm tái khẳng định vai trò thiết yếu của đánh giá đa hạt giống và của việc báo cáo kết quả một cách trung thực, kể cả khi một số kết quả không như kỳ vọng ban đầu.

TÀI LIỆU THAM KHẢO

- [1] P. Fazzini, G. La Tona, M. Diez, and M. C. Di Piazza. Enhanced forecasting of shipboard electrical power demand using multivariate input and variational mode decomposition with mode selection (vmdms). *Scientific Reports*, 2025.
- [2] Y. Wang, H. Wu, J. Dong, G. Qin, H. Zhang, Y. Liu, Y. Qiu, J. Wang, and M. Long. Timexer: Empowering transformers for time series forecasting with exogenous variables. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.
- [3] C. Yang, H. Li, Y. Ma, Y. Huang, and X. Chu. Enhanced tsmixer model for the prediction and control of particulate matter (e-tsmixer). *Sustainability*, 17(7):2933, 2025.